Trabajo Práctico Final Integrador: Análisis y Optimización del Negocio con Python y pandas

Materia: Introducción al Análisis de Datos

Institución: UTN FRMDP – Extensión Áulica Necochea

Profesor: Matías Gigena

Modalidad: Grupal (Defensa oral y entrega de Notebook / Reporte)

1. Objetivo del Trabajo Práctico

Los alumnos deberán asumir el rol de **Consultores de Datos Junior**. Partiendo de un dataset provisto por el profesor (que contendrá "ruido", valores faltantes, duplicados y anomalías), tendrán que aplicar todas las herramientas vistas en el curso para limpiar, transformar, explorar, visualizar los datos y, finalmente, **fundamentar estrategias de negocio accionables**.

2. Estructura Obligatoria del Informe y Notebook de Trabajo

El proyecto se evaluará en base a 4 etapas fundamentales que replican el flujo de trabajo profesional:

Fase 1: Diagnóstico e Inspección Inicial (Módulo 1)

- Carga del archivo crudo utilizando `pandas`.
- Análisis estructural: dimensiones, tipos de datos y detección inicial de anomalías.
- Auditoría de calidad: conteo y localización de valores nulos (`NaN`) y filas duplicadas exactas.

Fase 2: Limpieza y Transformación ETL (Módulo 2)

- **Decisión y aplicación de criterios de limpieza:** Justificar si se eliminan, imputan o conservan los valores nulos (aplicando las reglas analizadas en clase: porcentaje de impacto, criticidad del negocio y tipo de variable).
- **Tratamiento de duplicados:** Eliminación con `drop_duplicates()`.

- **Creación de variables derivadas:** Generación de columnas calculadas clave (por ejemplo, `monto_total = precio_unitario * cantidad`, descuentos por volumen, etc.).
- **Integración / Agrupamiento:** Uso de `groupby()` y agregaciones múltiples (`agg()`) para consolidar métricas por sucursal, producto, categoría o vendedor.

Fase 3: Análisis Exploratorio de Datos (EDA) y Visualización (Módulo 3)

- **Estadísticas Descriptivas:** Cálculo de media, mediana, desviación estándar y percentiles de las variables financieras. Explicación de asimetrías (diferencia entre media y mediana).
- **Detección de Outliers:** Aplicación de la regla del Rango Intercuartílico (IQR = Q3 - Q1) y los límites de tolerancia (1.5 * QR) para identificar transacciones atípicas.
- **Visualización Profesional:**
    - Un histograma o gráfico de densidad con curvas KDE para mostrar la distribución de los montos.
    - Un diagrama de caja (*Boxplot*) comparativo para analizar la dispersión por sucursal o categoría.
    - Un gráfico de barras o de dispersión (*Scatterplot* con `hue`) personalizado con títulos, etiquetas claras y exportado en alta resolución (`dpi=300`).

Fase 4: Conclusiones y Propuestas Estratégicas para el Negocio

Esta es la sección más importante para la defensa grupal. A partir de los hallazgos técnicos, el grupo deberá responder:

1. **¿Qué está pasando en el negocio?** (Ej: ¿Qué sucursal lidera las ventas? ¿Qué categorías tienen tickets más altos? ¿Existen errores de carga o ventas mayoristas reales entre los *outliers*?).
2. **Estrategias orientadas a la eficiencia:** Proponer al menos **dos medidas concretas** basadas estrictamente en los datos (ej: reasignación de stock, campañas focalizadas en categorías de bajo rendimiento, automatización de validación de datos en origen para evitar nulos).

3. Criterios de Evaluación para la Defensa Grupal

- **Rigurosidad Técnica (40%):** Correcto uso de `pandas`, sintaxis de limpieza, lógica en los cruces/agrupamientos y precisión en los cálculos estadísticos.
- **Interpretación Visual y Estadística (30%):** Capacidad de explicar qué muestra un histograma, un *Boxplot* o un diagrama de dispersión, justificando el uso de la mediana frente a la media si hay sesgos.

- **Fundamentación de Decisiones de Negocio (30%):** Coherencia entre los hallazgos de los datos y las propuestas estratégicas presentadas. No se evalúa solo el código, sino **qué decisiones se toman gracias a él**.